

עבודה 1 – מבוא למודלים גרפיים ולמידה עמוקה

וקטורים אקראיים

1. נגדיר סדרה אינסופית $\langle A_i \rangle_{i=1}^{\infty}$ כך שלכל $i > n$: $A_i = \emptyset$. ברור שזו סדרה של קבוצות זרות כי הן ריקות. אזי:

$$\begin{aligned}\sum_{i=1}^n P(A_i) &= \sum_{i=1}^n P(A_i) + 0 = \sum_{i=1}^n P(A_i) + \sum_{i=n+1}^{\infty} 0 = \sum_{i=1}^n P(A_i) + \sum_{i=n+1}^{\infty} P(A_i) = \sum_{i=1}^{\infty} P(A_i) = P\left(\bigcup_{i=1}^{\infty} A_i\right) \\ &= P\left(\left(\bigcup_{i=1}^n A_i\right) \cup \left(\bigcup_{i=n+1}^{\infty} A_i\right)\right) = P\left(\left(\bigcup_{i=1}^n A_i\right) \cup \left(\bigcup_{i=n+1}^{\infty} \emptyset\right)\right) = P\left(\left(\bigcup_{i=1}^n A_i\right) \cup \emptyset\right) \\ &= P\left(\bigcup_{i=1}^n A_i\right)\end{aligned}$$

כנדרש.

2. יהי מאורע A . אזי:

$$1 = P(\Omega) = P(A \cup A^c) = P(A) + P(A^c) \rightarrow P(A^c) = 1 - P(A)$$

כנדרש.

3. (1) $X^{-1}(B) = \Omega$ כיוון שלכל קלט של X הפלט שלו ב- B . אזי $P(X^{-1}(B)) = 1$

(2) $X^{-1}(B) = \emptyset$ כיוון שאין ב- B אף איבר שיכול להיות פלט של X . אזי $P(X^{-1}(B)) = 0$.

4. זו לא פונקציית CDF כיוון שהיא לא רציפה מימין ב- $x = 42$.


5. (1) X רציף לכן ההסתברות שיקבל כל ערך ספציפי היא 0.

(2) $B = \{x\}$ עבור $x \in R^n$ כלשהו.


(3) אם כל B_i בת מנייה אז האיחוד שלהן בת מנייה ואז מתקבלת הסתברות 0 כיוון ש- X רציף.

.6

$$f(x) = \begin{cases} 0 & : x < 1 \\ \frac{1}{6} & : 1 \leq x < 2 \\ \frac{2}{6} & : 2 \leq x < 3 \\ \frac{3}{6} & : 3 \leq x < 4 \\ \frac{4}{6} & : 4 \leq x < 5 \\ \frac{5}{6} & : 5 \leq x < 6 \\ 1 & : x \geq 6 \end{cases}$$



$$p(x) = \begin{cases} \frac{1}{6} & : x = 1 \\ \frac{1}{6} & : x = 2 \\ \frac{1}{6} & : x = 3 \\ \frac{1}{6} & : x = 4 \\ \frac{1}{6} & : x = 5 \\ \frac{1}{6} & : x = 6 \end{cases}$$



.7

$$p(x_3, x_4, x_5) = \sum_{x_1, x_2} p(x_1, x_2, x_3, x_4, x_5)$$

.8

$$E(X) = \frac{1}{6} \cdot 1 + \frac{1}{6} \cdot 2 + \frac{1}{6} \cdot 3 + \frac{1}{6} \cdot 4 + \frac{1}{6} \cdot 5 + \frac{1}{6} \cdot 6 = \frac{1}{6} (1 + 2 + 3 + 4 + 5 + 6) = \frac{1}{6} \cdot 21 = 3.5$$

$$(xx^T)^T = (x^T)^T x^T = xx^T \quad .9 \quad \text{כנדרש.}$$

10. נסמן כל תא ב- X ע"י $X_{i,j}$. אזי:

$$E(X^T)_{i,j} = E(X_{j,i}) = (E(X)^T)_{i,j}$$

11. מהגדרת כפל מטריצות, $(XX^T)_{i,j} = X_i X_j$, אזי $E(XX^T)_{i,j} = E(X_i X_j) = (R_X)_{i,j}$.

12. ההוכחה זהה לשאלה 9.

$$(\Sigma_X)_{i,j} = E((X - \mu)(X - \mu)^T)_{i,j} = E((X - \mu)_i (X - \mu)_j) = E((X_i - E(X_i))(X_j - E(X_j))) \quad 13.$$

$$(\Sigma_X)_{i,i} = E((X_i - E(X_i))^2) = Var(X) \quad 14.$$

$$(\Sigma_X)^T = E((X - \mu)(X - \mu)^T) = R_{X-\mu} \quad 15.$$

16. (1) מתוך זהות ידוע על *covariance*:

$$(\Sigma)_{i,j} = E((X_i - E(X_i))(X_j - E(X_j))) = E(X_i X_j) - \mu_i \mu_j = (E(XX^T) - \mu \mu^T)_{i,j}$$

$$E((X - \mu)X^T)_{i,j} = E((X - \mu)_i X_j) = E(X_i X_j - \mu_i X_j) = E(X_i X_j) - \mu_i E(X_j) = E(X_i X_j) - \mu_i \mu_j \quad (2)$$

אזי זו מטריצת השוניות המשותפות כלומר Σ .

$$E(X(X - \mu)^T) = (E(X(X - \mu)^T)^T)^T = E((X - \mu)X^T)^T = \Sigma^T = \Sigma \quad (3) \text{ לפי התוצאה הקודמת:}$$

$$R_{YX} = E(YX^T) = (E(YX^T)^T)^T = E(XY^T)^T = (R_{XY})^T \quad (a) \quad 17.$$

(b)

$$\Sigma_{YX} = E((Y - \mu_Y)(X - \mu_X)^T) = (E((Y - \mu_Y)(X - \mu_X)^T))^T = E((X - \mu_X)(Y - \mu_Y)^T)^T = (\Sigma_{XY})^T$$

$$(c) \quad (\Sigma_{XY})_{i,j} = E((X - \mu_X)(Y - \mu_Y)^T)_{i,j} = E((X - \mu_X)_i(Y - \mu_Y)_j) = E((X_i - E(X_i))(Y_j - E(Y_j))) = E(X_i Y_j) - E(X_i)E(Y_j) = (R_{XY} - \mu_X \mu_Y^T)_{i,j}$$

$$\mu_Y = E(AX + b) = E(A)E(X) + E(b) = A\mu_X + b \quad .18$$

$$\begin{aligned} \Sigma_Y &= \Sigma_{AX+b} = E((AX + b - \mu_Y)(AX + b - \mu_Y)^T) = \\ E((AX + b - A\mu_X - b)(AX + b - A\mu_X - b)^T) &= E((AX - A\mu_X)(AX - A\mu_X)^T) = \\ E(A(X - \mu_X)(X - \mu_X)^T A^T) &= E(A)E((X - \mu_X)(X - \mu_X)^T)E(A^T) = A \Sigma_X A^T \end{aligned}$$

$$.19 \text{ נסמן: } Y = 1^T X \text{ אזי לפי הסעיף הקודם: } \Sigma_Y = 1^T \Sigma_X 1 = \sigma^2 1^T \cdot 1 = \sigma^2 n$$

$$.20 \text{ נניח ש-} A, B \text{ ב"ת בהינתן } C \text{ אזי:}$$

$$\begin{aligned} P(A|B, C) &= \frac{P(A \cap B \cap C)}{P(B \cap C)} = \frac{P(A \cap B \cap C)P(C)}{P(B \cap C)P(C)} = P(A \cap B|C) \cdot \frac{P(C)}{P(B \cap C)} = P(A|C)P(B|C) \cdot P(B|C)^{-1} \\ &= P(A|C) \end{aligned}$$

$$\text{כעת נניח ש-} P(A|B, C) = P(A|C) \text{ אזי:}$$

$$P(A \cap B|C) = \frac{P(A \cap B \cap C)}{P(C)} = \frac{P(A \cap B \cap C)P(B \cap C)}{P(C)P(B \cap C)} = P(A|B, C)P(B|C) = P(A|C)P(B|C)$$

והתנאי השלישי גם שקול בגלל הסימטריות של אי תלות כלפי A, B .

$$.21 \quad E(1_A) = 1 \cdot P(A) + 0 \cdot P(A^C) = P(A)$$

$$.22 \text{ כפי שלמדנו: } R_Z = \begin{bmatrix} R_X & R_{XY} \\ R_{YX} & R_Y \end{bmatrix} \text{ אבל בהגדרה } R_{XY}, R_{YX} = 0 \text{ כאשר } X, Y \text{ אורתוגונליים לכן:}$$

$$R_Z = \begin{bmatrix} R_X & 0 \\ 0 & R_Y \end{bmatrix}$$

$$\begin{aligned} \text{באופן דומה אנו יודעים ש-} \Sigma_Z &= \begin{bmatrix} \Sigma_X & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_Y \end{bmatrix} \text{ אבל בהגדרה } \Sigma_{XY}, \Sigma_{YX} = 0 \text{ כאשר } X, Y \text{ בלתי מתואמים לכן} \\ \Sigma_Z &= \begin{bmatrix} \Sigma_X & 0 \\ 0 & \Sigma_Y \end{bmatrix} \end{aligned}$$

23. יהיו X, Y וקטורים מקריים בלתי תלויים. ראשית נראה שכל X_i, Y_j ב"ת:

$$\begin{aligned} p(x_i, y_j) &= \sum_{\substack{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n \\ y_1, \dots, y_{j-1}, y_{j+1}, \dots, y_m}} p(x, y) = \sum_{\substack{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n \\ y_1, \dots, y_{j-1}, y_{j+1}, \dots, y_m}} p(x)p(y) \\ &= \sum_{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n} \sum_{y_1, \dots, y_{j-1}, y_{j+1}, \dots, y_m} p(x)p(y) = \sum_{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n} p(x) \sum_{y_1, \dots, y_{j-1}, y_{j+1}, \dots, y_m} p(y) \\ &= \sum_{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n} p(x)p(y_j) = p(x_i)p(y_j) \end{aligned}$$

אזי לכל זוג X_i, Y_j הם ב"ת. לכן:

$$E(XY^T)_{i,j} = E(X_i Y_j) = E(X_i)E(Y_j) = (E(X)E(Y^T))_{i,j}$$

כנדרש.

$$p_{X_1}(1) = p(1,0) + p(1,1) = 0.4, p_{X_1}(0) = p(0,0) + p(0,1) = 0.6 \quad (a) \quad 24.$$

$$p_{X_2}(1) = p(0,1) + p(1,1) = 0.2, p_{X_2}(0) = p(0,0) + p(1,0) = 0.8$$

$$E(X) = \begin{bmatrix} 0.4 \\ 0.2 \end{bmatrix} \text{ אזי } E(X_2) = p_{X_2}(1) = 0.2, E(X_1) = p_{X_1}(1) = 0.4 \quad (b)$$

$$E(X_1 X_2) = p(1,1) = 0.1, E(X_2^2) = E(X_2) = 0.2, E(X_1^2) = E(X_1) = 0.4 \quad (c)$$

$$R_{XY} = \begin{bmatrix} 0.4 & 0.1 \\ 0.1 & 0.2 \end{bmatrix}$$

$$\Sigma_Y = \begin{bmatrix} 0.4 - 0.4^2 & 0.1 - 0.4 \cdot 0.2 \\ 0.1 - 0.4 \cdot 0.2 & 0.2 - 0.2^2 \end{bmatrix} = \begin{bmatrix} 0.24 & 0.02 \\ 0.02 & 0.16 \end{bmatrix} \quad (d)$$

(e,f) המשתנים מתואמים כיוון שהשונות המשותפת שלהם היא לא 0 (היא 0.02). כיוון שהם מתואמים, הם תלויים.

$$25. (a) p_{X_1} \text{ ו- } p_{X_2} \text{ שניהם מקבלים ערך של 0.5 עבור 0 ו-1.}$$

$$E(X) = \begin{bmatrix} 0.5 \\ 0.5 \end{bmatrix} \text{ אזי } E(X_1) = E(X_2) = 0.5 \cdot 1 + 0.5 \cdot 0 = 0.5 \quad (b)$$

$$E(X_1 X_2) = p(1,1) = 0.25, E(X_1^2) = E(X_2^2) = E(X_1) = E(X_2) = 0.5 \quad (c) \text{ אזי:}$$

$$\Sigma_X = \begin{bmatrix} 0.5 - 0.5^2 & 0.25 - 0.5^2 \\ 0.25 - 0.5^2 & 0.5 - 0.5^2 \end{bmatrix} = \begin{bmatrix} 0.25 & 0 \\ 0 & 0.25 \end{bmatrix}$$

$$(d) \text{ כן כיוון ש- } p(x_1, x_2) = 0.25 = 0.5^2 = p(x_1)p(x_2)$$

(e) כן כיוון שבמטריצת הקורלציה ניתן לראות שהשונות המשותפת של X_1, X_2 היא 0.

$$(f) p_Y(0,0) = p(0,0) = 0.25, p_Y(2,0) = p(1,1) = 0.25, p_Y(1,1) = p(1,0) + p(0,1) = 0.5$$

$$(g) p_{Y_1}(2) = p_Y(2,0) = 0.25, p_{Y_1}(1) = p_Y(1,1) = 0.5, p_{Y_1}(0) = p_Y(0,0) = 0.25.$$

$$p_{Y_2}(1) = p_Y(1,1) = 0.5, p_{Y_2}(0) = p_Y(0,0) + p_Y(2,0) = 0.25 + 0.25 = 0.5$$

$$E(Y) = \begin{bmatrix} 1 \\ 0.5 \end{bmatrix} \text{ אזי: } E(Y_2) = p_{Y_2}(1) = 0.5, E(Y_1) = E(X_1) + E(X_2) = 0.5 + 0.5 = 1 \quad (h)$$

$$\text{אזי: } E(Y_1 Y_2) = p_Y(1,1) = 0.5, E(Y_2^2) = E(Y_2) = 0.5, E(Y_1^2) = 1 \cdot 0.5 + 4 \cdot 0.25 = 1.5 \quad (i)$$

$$\Sigma_Y = \begin{bmatrix} 1.5 - 1^2 & 0.5 - 1 \cdot 0.5 \\ 0.5 - 1 \cdot 0.5 & 0.5 - 0.5^2 \end{bmatrix} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.25 \end{bmatrix}$$

$$p_Y(0,0) = 0.25 \neq 0.25 \cdot 0.5 = p_{Y_1}(0)p_{Y_2}(0) \quad (j)$$

(k) ניתן לראות במטריצה שהשונוות המשותפת של Y_1, Y_2 היא 0 לכן הם בלתי מתואמים.

26. נניח ש- X, Y ב"ת בהינתן Z . אזי:

$$p(x|y, z) = \frac{p(x, y, z)}{p(y, z)} = \frac{p(x, y, z)p(z)}{p(y, z)p(z)} = p(x, y|z) \cdot \frac{p(z)}{p(y, z)} = p(x|z)p(y|z) \cdot p(y|z)^{-1} = p(x|z)$$

כעת נניח ש- $p(x|y, z) = p(x|z)$. אזי:

$$p(x, y|z) = \frac{p(x, y, z)}{p(z)} = \frac{p(x, y, z)p(y, z)}{p(z)p(y, z)} = p(x|y, z)p(y|z) = p(x|z)p(y|z)$$

והתנאי השלישי גם שקול בגלל הסימטריות של אי תלות כלפי x, y .

27. (a) נבחין: $\exp(x + xz + yz) = \exp(x + xz) \exp(yz)$.

נגדיר: $f(x, z) = \exp(x + xz)$, $g(y, z) = \exp(yz)$, בתחום B , מחוץ לו f, g הן 0. אזי f, g אי-שליליות ומקיימות $p(x, y, z) = f(x, z)g(y, z)$ לכן X, Y ב"ת בהינתן Z .

(b) נשים לב שלפי עובדה 18, X ו- Y ב"ת בהינתן Z א"מ אפשר לפרק את הפונקציה $p(x, y, z)$ לשתי פונקציות f, g כך ש- $p(x, y, z) = f(x, z)g(y, z)$, כלומר לפרק את הפונקציית p לשתי פונקציות כאשר כל אחת תלויה בשתי משתנים. כדי להפריד את אחד המשתנים מהפונקציה נצטרך למצוא את פונקציית ההתפלגות השולית שלו כלומר לגזור לפי המשתנה, בגלל שהנגזרת של $\exp(x) \cdot x' = \exp(x)$ לא נוכל להפריד את אחד המשתנים מהפונקציה. ולכן לא נוכל למצוא f, g כאלה. (כי נקבל שלמשל הנגזרת לפי x היא $\exp(xy) \cdot yz$)

שרשראות מרקוב

1. (a)

x_1	x_3	$p(x_1, x_3)$
0	0	$(1 - \theta)^2$
0	1	$\theta(1 - \theta)$
1	0	$\theta(1 - \theta)$
1	1	θ^2

(b) $Y_1 = X_1$ אזי יש להם את אותה ההתפלגות.

(c) מתפלג ברנולי אזי $p(y_2) = \binom{2}{y_2} \theta^{y_2} (1 - \theta)^{2-y_2}$

(d) גם מתפלג ברנולי אזי $p(y_3) = \binom{3}{y_3} \theta^{y_3} (1 - \theta)^{3-y_3}$

הערה: בכל הסעיפים הבאים נניח שהמאורעות שמותנים בהם לא ריקים. למשל בהסתברות $p(y_1|x_1)$ אז $x_1 \in \{0,1\}$.

(e) $Y_1 = X_1$ לכן $p(y_1|x_1) = \begin{cases} 1 & \text{if } y_1 = x_1 \\ 0 & \text{if } y_1 \neq x_1 \end{cases}$

(f) $Y_2 = X_1 + X_2$ לכן: $p(y_2|x_1, x_2) = \begin{cases} 1 & \text{if } y_2 = x_1 + x_2 \\ 0 & \text{if } y_2 \neq x_1 + x_2 \end{cases}$

(g) נתון לנו y_2 וברור שלא צריך יותר מזה כדי לדעת את ההתפלגות של y_2 : $p(y_2'|y_1, y_2) = \begin{cases} 1 & \text{if } y_2' = y_2 \\ 0 & \text{if } y_2' \neq y_2 \end{cases}$

(h) $Y_3 = X_1 + X_2 + X_3$. כיוון שנתונים X_1, X_2 מתקבל ש- Y_3 מתפלג באופן דומה ל- X_3 :

$$p(y_3|x_1, x_2) = \begin{cases} \theta & \text{if } y_3 = x_1 + x_2 + 1 \\ 1 - \theta & \text{if } y_3 = x_1 + x_2 \end{cases}$$

(i) $X_1 = Y_1$ לכן זה שנתון Y_1 לא משנה דבר וההתפלגות היא כמו זו מהסעיף הקודם.

(j) $Y_2 = X_1 + X_2$ לכן שוב לא נוספו שום נתונים חדשים והתשובה היא כמו סעיף h.

(k) $Y_3 = Y_2 + X_3$ לכן: $p(y_3|x_1, x_2, x_3, y_2) = \begin{cases} 1 & \text{if } y_3 = y_2 + x_3 \\ 0 & \text{if } y_3 \neq y_2 + x_3 \end{cases}$

(l) נתון Y_3 לכן מתקבל: $p(y_3'|y_1, y_2, y_3) = \begin{cases} 1 & \text{if } y_3' = y_3 \\ 0 & \text{if } y_3' \neq y_3 \end{cases}$

(m) כל המשתנים ב"ת לכן $p(x_i|x_{1:(i-1)}) = p(x_i) = p(x_i|x_{1:(i-1)})$. כלומר זו שרשרת מרקוב פשוט בגלל שהמשתנים הקדומים לא משנים כלל עבור משתנה כלשהו.

(n) נגדיר את $y_0 = 0$. נתבונן ב- $p(y_i|y_{1:(i-1)})$:

$$p(y_i|y_{1:(i-1)}) = \frac{p(y_{1:i})}{p(y_{1:(i-1)})} = \frac{p(\cap_{j=1}^i X_j = y_j - y_{j-1})}{p(\cap_{j=1}^{i-1} X_j = y_j - y_{j-1})} = \frac{p((X_i = y_i - y_{i-1}) \cap (\cap_{j=1}^{i-1} X_j = y_j - y_{j-1}))}{p(\cap_{j=1}^{i-1} X_j = y_j - y_{j-1})}$$

כיוון שה- X_i ים ב"ת:

$$\begin{aligned}
\frac{p\left((X_i = y_i - y_{i-1}) \cap \left(\bigcap_{j=1}^{i-1} X_j = y_j - y_{j-1}\right)\right)}{p\left(\bigcap_{j=1}^{i-1} X_j = y_j - y_{j-1}\right)} &= \frac{p(X_i = y_i - y_{i-1})p\left(\bigcap_{j=1}^{i-1} X_j = y_j - y_{j-1}\right)}{p\left(\bigcap_{j=1}^{i-1} X_j = y_j - y_{j-1}\right)} \\
&= p(X_i = y_i - y_{i-1}) = \frac{p(X_i = y_i - y_{i-1})p(y_{i-1})}{p(y_{i-1})} = \frac{p(X_i = y_i - y_{i-1} \cap y_{i-1})}{p(y_{i-1})} \\
&= \frac{p(y_i, y_{i-1})}{p(y_{i-1})} = p(y_i | y_{i-1})
\end{aligned}$$

כנדרש.

2. יהיו $P_1, P_2 \in M_{n \times n}^{\mathbb{R}}$ מטריצות מעבר מרקוביות, ולכן סטוכסטיות בפרט, נשים לב כי לכל וקטור שורה במטריצות אלה: $\sum_{i=1}^n P_{1ij} = 1 = \sum_{i=1}^n P_{2ij}$ נסתכל על וקטור שורה של המכפלה:

$$\sum_{i=1}^n (P_1 P_2)_{ji} = \sum_{i=1}^n \left(\sum_{k=1}^n (P_1)_{jk} (P_2)_{ki} \right) = \sum_{k=1}^n (P_1)_{jk} \left(\sum_{i=1}^n (P_2)_{ki} \right) = \sum_{k=1}^n (P_1)_{jk} \cdot 1 = 1$$

הסבר: ניתן להחליף את סדר הסכימה בסגול שהסכום $\sum_{k=1}^n P_{ik}$ לא תלוי ב- i

3. השיוויון הראשון- נכון כיוון שאנו מפצלים את המאורע $X_{n+1} = j$ למאורעות זרים שמהווים חלוקה של כל המאורעות האפשריים.

השיוויון השני- נכון לפי נוסחת בייס.

השיוויון השלישי- נכון כיוון שהמשתנים הם מרקוביים.

השיוויון הרביעי- נכון כיוון שכפל הוא קומוטטיבי.

השיוויון החמישי- נכון לפי ההגדרה של הפונקציות p, p_n .

השיוויון השישי- נכון לפי הנחת האינדוקציה.

השיוויון האחרון- נכון לפי הגדרת כפל מטריצות.

4. נסמן ב- π_0 את ההסתברות ההתחלתית, ונקבל מהטענה הקודמת ש:

$$\pi_n = p(x_n) = p_n(i, j) = P^n_{ij} = \pi_0 P^n$$

5. (a) נסמן ב- π^j את האיבר ה- j בוקטור π . ניזכר שלפי הגדרת כפל מטריצות ריבועיות בתא ה- (i, j) של המטריצה $A \cdot B$

יש את ה-dot product של השורה ה- i של A והעמודה ה- j של B . נבחין שבעמודה ה- j של P יש את הוקטור $\pi^j \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}$.

לכל וקטור v , $\pi^j \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} = \pi^j \sum_{i=1}^N v^i$ אזי: $(P^2)_{i,j} = \pi^j \sum_{i=1}^N \pi^i$ אבל הסכום $\sum_{i=1}^N \pi^i$ הוא 1 מהגדרת וקטור סטוכסטי לכן $(P^2)_{i,j} = \pi^j = (P)_{i,j}$, כנדרש.

(b) הוכחנו עבור $n = 2$. נניח נכונות עבור $n > 2$ כלשהו. אזי: $P^{n+1} = P^n P = PP = P$ כנדרש.

(c) $(\tilde{\pi} P)_j = \sum_{i=1}^N \tilde{\pi}^i (P)_{i,j} = \sum_{i=1}^N \tilde{\pi}^i \pi^j = \pi^j \sum_{i=1}^N \tilde{\pi}^i = \pi^j \cdot 1 = \pi^j$ כנדרש.

(d) לפי השאלה הקודמת: $\pi_n = \pi_0 P^n$. אבל ראינו ש- $P^n = P$ לכן $\pi_n = \pi_0 P$. ראינו ש- $\pi_n = \pi_0 P$ לכן $\pi_n = \pi_0 P$.

מטריצות SPD, מכפלה פנימית, נורמות ומרחקים

1. תהי A מטריצה SPD. אזי אין לה את הע"ע 0. לכן $\text{Ker}(A) = \{0\}$ לכן היא הפיכה.

2. תהי Q מטריצה SPD ושני וקטורים x, y .

קומוטטיביות:

$$\langle x, y \rangle_Q = x^T Q y = (x^T Q y)^T = y^T Q^T x^{TT} = y^T Q x = \langle y, x \rangle_Q$$

משמר חיבור וקטורים:

$$\langle x + y, z \rangle_Q = (x + y)^T Q z = (x^T + y^T) Q z = x^T Q z + y^T Q z = \langle x, z \rangle_Q + \langle y, z \rangle_Q$$

משמר כפל בסקלר:




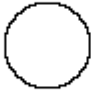

$$\langle cx, y \rangle_Q = (cx)^T Q y = cx^T Q y = c \langle x, y \rangle_Q$$

מכפלה של כל וקטור עם עצמו אי-שלילית, ורק עבור וקטור ה-0 מתקבל 0: זו ההגדרה של מטריצה PD.

$$3\|x\|_Q = \sqrt{\langle x, x \rangle_Q} = \sqrt{x^T Q x} = \sqrt{x^T L L^T x} = \sqrt{(L^T x)^T (L^T x)} = \|L^T x\|_I = \|L^T x\|_{l_2}$$

כנדרש.

תרגיל בתכנות 1

לפי מרחק $Q2$:	לפי מרחק l_1 :
	
לפי מרחק $Q3$:	לפי מרחק l_2 :
	
לפי מרחק $Q1$:	
	

וקטורים אקראיים גאוסיאנים

1. נבחין:

$$\begin{aligned} p(x) &= \frac{1}{\sqrt{(2\pi)^n}} \exp\left(-\frac{1}{2}\|x\|^2\right) = \frac{1}{\sqrt{(2\pi)^n}} \exp\left(-\frac{1}{2}\sum_{i=1}^n x_i^2\right) = \frac{1}{\sqrt{(2\pi)^n}} \prod_{i=1}^n \exp\left(-\frac{1}{2}x_i^2\right) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}x_i^2\right) = \prod_{i=1}^n N(x_i; 0, 1) \end{aligned}$$

עבור תת קבוצה J של אינדקסים מתוך $1, \dots, n$ נסמן ב- Jx את איברי הוקטור X עם אינדקסים שלא ב- J . נוכיח באינדוקציה על $|J| = k$ את התכונה הבאה: $p(Jx) = \prod_{i=1, i \notin J}^n N(x_i; 0, 1)$.

$k = 0$: כבר הוכחנו.

נניח נכונות עבור $|J| = k$ ונוכיח עבור קבוצה עם $|J| = k + 1$ (כאשר $k + 1 < n$). נבחר $j \in J$ כלשהו. נסמן $J' = J \setminus \{j\}$. נבחין ש- $|J'| = k$. אזי:

$$p(Jx) = \int_{-\infty}^{\infty} p(J'x) x_j = \int_{-\infty}^{\infty} \prod_{i=1, i \notin J'}^n N(x_i; 0, 1) x_j = \prod_{i=1, i \notin J}^n N(x_i; 0, 1) \int_{-\infty}^{\infty} N(x_j; 0, 1) dx_j = \prod_{i=1, i \notin J}^n N(x_i; 0, 1)$$

כנדרש. בהינתן x_s כלשהו, נגדיר את $J = \{1, \dots, n\} \setminus \{s\}$. אזי:

$$p(x_s) = p(Jx) = \prod_{i=1, i \notin J}^n N(x_i; 0, 1) = N(x_s; 0, 1)$$

אזי כל x_s מתפלג זהה עם התפלגות נורמלית סטנדרטית. כעת נוכיח אי-תלות: עבור קבוצה כלשהי S כל אינדקסים, נגדיר את $J = \{1, \dots, n\} \setminus S$. אזי:

$$p(x_i \text{ s.t. } i \in S) = p(Jx) = \prod_{i=1, i \notin J}^n N(x_i; 0, 1) = \prod_{i \in S} N(x_i; 0, 1) = \prod_{i \in S} p(x_i)$$

לכן בנוסף להתפלגות זהה, המשתנים גם בלתי תלויים לפי ההגדרה, מש"ל.

2. ממשפט 4 ומכך ש- X מתפלג גאוסיאני נקבל ש- Y מתפלג גאוסיאני, נחשב את התוחלת והשונות של Y :

$$\mathbb{E}(Y) = \mathbb{E}(aX + b) = a\mathbb{E}(X) + b = a\mu + b$$

$$\mathbb{V}(Y) = \mathbb{V}(aX + b) = a^2\mathbb{V}(X) = a^2\sigma^2$$

ולכן נקבל ש- $Y \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$

3. (a) נגדיר את A_i להיות וקטור שורה באורך n עם 1 בתא ה- i ו-0 בשאר. כמו ברמז: $X_i = A_i X$ לכל i . אזי כיוון שלמדנו שטרנספורמציה לינארית של וקטור גאוסיאני היא גם וקטור גאוסיאני:

$$X_i = A_i X \sim N(A_i \mu, A_i \Sigma A_i^T) = N(\mu_i, (\Sigma)_{i,i}) \text{ כנדרש.}$$

(b) עבור $S = i_1, \dots, i_k$ סדרת אינדקסים שונים מתוך $\{1, \dots, n\}$, נסמן $V_S = [V_{i_1} \dots V_{i_k}]^T$ עבור וקטור כלשהו V ונגדיר את A_S להיות מטריצה $k \times n$ כך שלכל $1 \leq j \leq k$: $(A_S)_{j,i_j} = 1$ ושאר המטריצה אפסים. אזי $(A_S V)_j = V_{i_j}$. כלומר $1 + 0 \dots 0 = V_{i_j}$ ובפרט $A_S X = X_S$. זו טרנספורמציה לינארית אזי כפי שלמדנו: $X_S \sim N(A_S \mu, A_S \Sigma A_S^T)$

כפי שהסברנו, $A_S \mu = \mu_S$. נתבונן במטריצה $A_S \Sigma A_S^T$. מתקיים:

$$(A_S \Sigma A_S^T)_{j,t} = \sum_{p=1}^n (A_S)_{j,p} (\Sigma A_S^T)_{p,t} = (\Sigma A_S^T)_{i_j,t} = \sum_{q=1}^n (\Sigma)_{i_j,q} (A_S^T)_{q,t} = \sum_{q=1}^n (\Sigma)_{i_j,q} (A_S)_{t,q} = (\Sigma)_{i_j,i_t}$$

אזי המטריצה $A_S \Sigma A_S^T$ היא פשוט המטריצה Σ שבה משמיטים שורות ועמודות המיוחסות לאיברים שלא ב- X_S , כך שאכן ב- μ, Σ יש את כל המידע הנדרש ע"מ לדעת את ההתפלגות של X_S , כנדרש.

4. נשתמש במשפט 10, תוך כדי ההנחה ש- X, Y ב"ת ונקבל:

$$Z = \begin{bmatrix} X \\ Y \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \Sigma_X & \Sigma_{XY} \\ \Sigma_{XY}^T & \Sigma_Y \end{bmatrix} \right) = \mathcal{N} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \Sigma_X & 0 \\ 0 & \Sigma_Y \end{bmatrix} \right)$$

5. (a) המטריצה $A = [I_{n \times n} \quad I_{n \times n}]$ מקיימת את הנדרש:

$$A \begin{bmatrix} X \\ Y \end{bmatrix} = [I_{n \times n} \quad I_{n \times n}] \begin{bmatrix} X \\ Y \end{bmatrix} = IX + IY = X + Y = Z$$

(b) לפי הוכחה קודמת, הוקטור $\begin{bmatrix} X \\ Y \end{bmatrix}$ הוא גאוסיאני. A ראינו כבר שטרנספורמציה לינארית על וקטור גאוסיאני היא גם גאוסיאנית אזי

$$Z \sim N \left(A \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, A \begin{bmatrix} \Sigma_X & 0 \\ 0 & \Sigma_Y \end{bmatrix} A^T \right) = N \left(\mu_X + \mu_Y, A \begin{bmatrix} \Sigma_X \\ \Sigma_Y \end{bmatrix} \right) = N(\mu_X + \mu_Y, \Sigma_X + \Sigma_Y)$$